

Jetson Orin Nano 기반 YOLOv8 무게 인식과 ACT

모방학습을 이용한 스마트 팩토리 분류·순차 적재 시스템

*이지용, 김한민, 정철훈, 장민기, 고병철

계명대학교 컴퓨터공학전공

e-mail : yeez0612@naver.com

Smart Factory Sorting and Sequential Stacking Using YOLOv8 Weight Recognition and ACT Imitation Learning on Jetson Orin Nano

Jiyong Lee, Hanmin Kim, Cheolhun Jeong, Mingi Jang, and Byoung Chul Ko
Dept. of Computer Engineering, Keimyung University

Abstract

This paper presents an edge-AI smart-factory cell that sorts products by weight and stacks them with a low-cost robot arm. On a Jetson Orin Nano, a YOLOv8n model (validation mAP50 86.3%) reads the 7-segment display of a digital scale; separating capture and inference threads raised the capture rate from 1.2 to 59.5 FPS, two-stage digital-zoom inference raised mid-range accuracy from 45% to 90%, and the cell sorted 91.7% of items correctly with an 810 ms response. When a bin reaches 118 g, a Model Context Protocol (MCP) trigger runs stage-specific ACT (Action Chunking with Transformers) policies on an SO-101 arm that stack the bin on the first floor, beside the first bin and on top of it. Because the arm was damaged after the field tests, the cell was rebuilt in MuJoCo with the same robot model, cameras and 30 Hz control to evaluate the stacking quantitatively. Per-stage success hides error accumulation: with the initial 100 demonstrations per stage the placements succeeded in 76%, 84% and 50% of trials but only 28% of three-stage sequences. Locating where the policy closed the gripper revealed two causes in the demonstration design rather than in the policy: the fixed jaw approached too close to the bin wall, and the scripted demonstrator

switched to another wall when the bin was rotated by more than about 8 degrees, which made the demonstrations bimodal. A 9 mm grasp clearance and a single grasp wall raised the sequence success with the same 100 demonstrations to []%, and 1000 demonstrations reached []% ([]% with DART noise injection).

I. 서론

제조·물류 현장은 인력 부족과 반복 작업에 따른 산업재해 문제로 자동화 수요가 커지고 있으며 산업용 로봇의 설치 대수도 꾸준히 늘고 있다[1]. 그러나 정해진 좌표를 반복하는 규칙 기반 셀은 제품 상태를 판정하거나 물체가 놓인 위치가 바뀌는 상황에 유연하게 대응하기 어렵다.

딥러닝 객체 탐지 모델인 YOLO[2] 계열은 실시간 산업 비전에 널리 쓰이며, YOLOv8[3]은 에지 장치에서도 동작한다. 로봇 조작에서는 ACT(Action Chunking with Transformers)[4]가 저가 로봇팔과 수십~수백 회의 원격조작 시연만으로 정밀한 조작을 학습할 수 있음을 보였고, LeRobot[5]은 이를 SO-101 같은 저가 로봇팔에서 바로 쓸 수 있도록 공개하였다. 그러나 무게 판정 같은 공정 판단과 학습 기반 조작을 하나의 에지 셀로 묶고, 앞선 적재 결과에 따라 다음 목표가 정해지는 순차 적재를 정량적으로 분석한 사례는 드물다. 모방학습은 앞선 동작의 작은 오차가

다음 상태를 학습 분포 밖으로 밀어내 오차가 누적되는 문제가 알려져 있으며[6], 순차 적재에서는 이 오차가 단계를 넘어 쌓인다.

본 논문은 Jetson Orin Nano 를 중심으로 디지털 저울의 7-segment 표시값을 YOLOv8로 판독하여 기준 무게(118g) 이상인 통을 선별하고, MCP(Model Context Protocol)[7] 트리거로 단계별 ACT 정책을 호출하여 SO-101 로봇팔이 통을 1층, 첫 통 옆, 첫 통 위(2층) 순서로 적재하는 셀을 구현한다. 현장 시험 이후 로봇팔이 파손되어 적재 성능을 다시 실측할 수 없었으므로, 같은 로봇 모델·카메라·제어 주기를 갖는 MuJoCo[8] 셀을 구성하여 적재를 정량적으로 평가한다. 기여는 다음과 같다. ① 무게 인식부터 순차 적재까지 이어지는 에지 셀을 구현하고 인식 성능을 실측하였다. ② 단계별 성공률과 함께 세 단계를 이어 수행하는 연속 성공률로 평가하여 순차 적재의 오차 누적을 보였다. ③ 실패가 일어난 파지 위치와 장면을 분석하여 원인이 정책보다 시연 설계(파지 여유, 잡는 벽의 일관성)에 있음을 밝히고, 시연 설계, 시연 수, 시연 잡음 주입(DART)[9]의 효과를 정량화하였다.

II. 시스템 구성

2.1 전체 구성

그림 1은 전체 구성이다. 3D 프린팅 색상 분류 컨베이어[10]는 TCS34725 RGB 센서로 큐브의 색을 판별하여 빨강·초록 큐브(불량)는 불량함으로, 파랑 큐브(정상)는 디지털 저울 위의 파란 통으로 보낸다. 컨베이어의 스테퍼 모터와 분류 서보는 Arduino Mega 2560이 제어하고 인식과 판단은 Jetson Orin Nano가 맡아, 저수준 모터 제어와 AI 추론을 분리하였다. Jetson은 저울 표시부를 USB 카메라(640×480)로 촬영해 무게를 판독하고, 통의 무게가 118g 이상이면 로봇 실행기에 MCP 트리거를 보낸다. 두 번째 USB 카메라에서는 큰 상자와 작은 상자를 구분하는 YOLOv8n-seg 모델을 함께 실행한다. 로봇은 통의 벽을 집어 1층, 첫 통 옆, 첫 통 위(2층) 순서로 적재하고 이 3단계 묶음을 옆으로 이어 가며 쌓는다. 적재 후에는 홈 자세로 돌아오며, 저울이 비면 빈 통을 저울에 올려 공정을 반복한다. FastAPI 서버는 영상 스트리밍, 성능 지표, 원격 시작·정지, LLM 기반 공정 질의 기능을 제공한다.




그림 1. 시스템 구성

2.2 7-segment 무게 인식

멀티스레드 비동기 처리. 단일 루프에서는 YOLO 추론이 카메라 캡처를 막아 캡처 속도가 1.2 FPS 까지 떨어졌다. 캡처 스레드는 최신 프레임만 공유 버퍼에 쓰고, 추론 스레드는 5초 주기로 그 프레임을 가져와 추론하며, 스트리밍은 비동기 생성기로 MJPEG을 보낸다. 공유 변수는 잠금(lock)으로 보호한다.

ONNX Runtime 병렬 추론. ONNX Runtime[11] 세션에 연산 스레드 6개, 병렬 실행 모드, 전체 그래프 최적화를 적용하여 단일 스레드 대비 추론 속도를 약 3배 높였다. 입력 크기는 세션에서 읽어 모델을 바꿔도 코드를 고치지 않도록 하였다.

2단계 디지털 줌. 카메라와 저울의 거리가 멀어지면 숫자가 작아져 '8'을 '1'로 오인식하였다. 1단계에서 전체 프레임으로 표시부(screen) 영역을 찾고, 2단계에서 그 영역을 여백 15화소와 함께 잘라 640×640으로 확대한 뒤 숫자를 다시 탐지하여, 거리와 관계없이 숫자가 입력 전체를 차지하게 하였다.

4단계 숫자 조합. YOLO는 한 숫자에 여러 상자를 내어 '118'이 '111111888'로 조합되었다. ① 숫자가 아닌 클래스 제거, ② IoU 0.4 기준 NMS, ③ x 범위를 자릿수(3)로 나눠 구역별 최고 신뢰도 선택, ④ 자릿수가 모자라면 원래 탐지의 밀도로 같은 숫자가 반복된 자리를 복원하는 순서로 무게를 조합한다(그림 2).




그림 2. 7-segment 무게 인식 파이프라인

2.3 ACT 기반 순차 적재

로봇은 그리퍼를 포함해 6 개 관절을 갖는 SO-101 팔로워이며, 손목 카메라(front)와 상단 카메라(top)를 쓴다. 시연은 사람이 리더함을 움직이면 팔로워가 따라 움직이는 원격조작으로, 30Hz로 영상과 관절값을 기록해 단계마다 100 회와 200 회의 두 차례 수집하였다.

ACT는 현재 영상과 관절값으로부터 앞으로 $k=100$ 스텝의 관절 목표값(행동 청크)을 한 번에 예측한다. ResNet18[12] 영상 특징과 관절값을 Transformer[13] 인코더-디코더로 처리하고, 시연의 다양성은 CVAE 잠재변수로 흡수하며, 손실은 L1 재구성 오차와 KL 항(가중치 10)의 합이다[4]. 별도의 객체 검출 없이 영상에서 통의 위치를 스스로 익힌다. LeRobot의 ACT는 작업 지시문을 입력으로 쓰지 않으므로 1 층·옆·2 층 단계마다 정책 π_1, π_2, π_3 을 따로 학습하였다. 학습은 PC(NVIDIA L4, RTX 3060)에서 하고 체크포인트만 Jetson Orin Nano로 옮겨 실행하였다.

실행기는 MCP TCP 서버(포트 8765)에서 run 신호를 기다리다(WAIT) 해당 단계의 정책을 실행하고(RUNNING), 시작 자세로 돌아온 뒤(RETURN_HOME) 다음 신호를 기다린다. 실행 중에 들어온 신호는 무시하고, 세 단계를 마치면 DONE 상태에서 reset 신호를 기다린다. Jetson에서는 스레드 수 제한, CUDA 지연 로딩, 자동 혼합 정밀도를 적용하였다.

III. 시뮬레이션 기반 적재 평가

3.1 시뮬레이션 셀

현장 시험 이후 로봇팔이 파손되어 적재 결과를 다시 측정할 수 없었다. 이에 MuJoCo[8]로 실제 셀을 재현하였다(그림 3). 로봇은 공식 SO-101 모델[14]의 손목 카메라 버전으로 STS3215 서보의 위치 제어 특성을 포함하며,

카메라 배치, 제어 주기(30Hz), 관절 목표값 행동 공간을 실제와 같게 하였다. 영상은 실제 경량 추론 설정과 같은 160×120 을 쓴다. 분류 통은 공개 모델의 출력 무게(통 33g)와 시연 영상으로부터 $64 \times 64 \times 52\text{mm}$ (벽 2mm)로 정하고 내부 큐브를 포함해 123g으로 두었다. 저울 위 통은 위치 $\pm 20\text{mm}$, 방향 $\pm 20^\circ$, 먼저 쌓인 통은 목표에서 $\pm 8\text{mm}$, $\pm 5^\circ$ 로 무작위화하였다.




그림 3. 시뮬레이션 셀 (a) 전체 (b) 손목 카메라 (c) 상단 카메라

3.2 시연 설계와 학습

원격조작 대신 역기구학 기반 스크립트 전문가로 시연을 만들었으며, ACT 원 논문도 시뮬레이션 과제에서 스크립트 시연을 사용하였고[4], 시연을 자동으로 만들어 데이터 양을 늘리는 방법도 연구되고 있다[15]. 전문가는 통의 앞벽(로봇 쪽 벽)을 고정 집게는 바깥, 움직이는 집게는 안쪽에 두고 집어 옮기며, 경유점 사이를 최소 저크 궤적으로 잇고 구간 속도($\pm 10\%$)와 경유점 위치(최대 $\pm 6\text{mm}$)를 흔들러 사람 시연의 변동을 흉내 냈다. 특히 고정 집게를 벽 바깥 9mm에 두고 내려가도록 하여, 집게가 벽을 사이에 둘 수 있는 범위(바깥 0~17mm)의 가운데로 접근하게 하였다. 초기 설계(여유 1.5mm)는 안쪽으로 3mm만 어긋나도 집게가 벽 위에 걸렸으나, 이 설계는 $\pm 9\text{mm}$ 의 위치 오차에서도 파지에 성공하였다(표 1, 전문가 시험 각 4~6 회). 또한 통이 얼마나 돌아가 있는 늘 같은 벽을 잡게 하였다. 로봇을 가장 많이 향한 벽을 고르면 통이 약 8° 넘게 돌아갔을 때 잡는 벽이 앞벽에서 옆벽으로 바뀌어, 카메라에는 거의 같은 장면인데 시연 동작이 두 갈래로 나뉘기 때문이다(4.2 절). 시연은 270 스텝(9 초)이며 성공한 것만 남겼다(전문가 성공률 1 층 []%, 옆 []%, 2 층 []%).

표 1. 파지 위치 오차에 따른 시연 성공률 (%)

벽 법선 오차 (mm)	-12	-9	-6	-3	0	+6	+9
여유 1.5mm	0	0	17	100	100	100	100
여유 9mm	75	100	100	100	100	100	100

개선안으로 DART[9] 잡음 주입을 적용하였다. 시연 중

실제로 실행하는 관절 목표에 상관 잡음(Ornstein-Uhlenbeck, $\sigma=0.005\text{rad}$)을 더하되 기록하는 정답은 원래 궤적으로 두어, 궤도에서 벗어난 상태에서 되돌아오는 동작을 함께 학습하게 하였다. 학습은 실제 시스템과 같은 LeRobot 0.3.3 ACT 기본 설정(체크 100, 배치 8, AdamW 학습률 1×10^{-5})으로 단계별 30,000 스텝 수행하였으며, 시연 영상은 JPEG(품질 90)로 저장하였다.

3.3 평가 방법

단계별 평가는 앞 단계 통을 목표 근처에 미리 둔 상태에서 해당 정책만 50 회 실행한다. 연속 평가는 실제 셀처럼 $\pi_1 \rightarrow \pi_2 \rightarrow \pi_3$ 을 같은 장면에서 이어서 실행하고 실행마다 홈 자세로 복귀한다(50 회). 통 중심이 목표에서 15mm, 높이가 8mm, 기울기가 10° 이내이고 먼저 쌓인 통이 10mm 이상 밀리지 않으면 성공으로 보았으며, 평가 장면은 시연에 쓰지 않은 난수 시드로 만들었다.

IV. 실험 결과

4.1 무게 인식

표 2는 두 YOLOv8 모델의 학습 결과(50 에폭, 입력 640, 마지막 에폭의 검증 집합 기준)이다. 숫자 모델은 숫자 0~9와 부호, 표시부(screen)의 13 개 클래스를 학습하여 mAP50 86.3%, mAP50-95 65.6%를 얻었다. mAP50-95가 낮은 것은 작은 숫자의 상자 위치가 엄격한 IoU 기준에서 어긋나기 때문이며, 이를 2 단계 디지털 줌과 숫자 조합 규칙으로 보완하였다.

표 2. YOLOv8 모델 학습 결과 (%)

모델	클래스	정밀도	재현율	mAP50	mAP50-95
숫자 (v8n)	13	85.4	80.8	86.3	65.6
상자 (v8n-seg)	2	99.2	100.0	99.5	96.5

Jetson Orin Nano에서 조건별 20 회 반복 측정하였다. 캡처·추론 분리로 캡처 속도는 1.2에서 59.5 FPS로 약 50 배 향상되었다(표 3). 2 단계 디지털 줌은 중거리 정확도를 45%에서 90%, 원거리를 15%에서 80%로 높였다(표 4). NMS 만으로는 '118'처럼 같은 숫자가 반복되는 경우 자릿수가 사라졌으나 ④단계 보완으로 복원되었고(표 5), 전체 후처리를 적용한 3 자리 조합 정확도는 87.5%(70/80)였다. 기준값 자동 분류의 정분류율은 91.7%(55/60), 인식부터 명령 전송까지 평균 응답 시간은 약 810ms였다. 오분류 5 건은 주로 조명이 고르지 않은 조건에서 '8'을 '1'로 읽은 경우였다.

표 3. 캡처 속도

구분	캡처 FPS	추론 주기
단일 루프	1.2	매 프레임
캡처·추론 분리	59.5	5 초

표 4. 거리별 인식 정확도 (%)

촬영 거리	1 단계만	2 단계 줌
근거리 (20cm 이내)	95	95
중거리 (30~50cm)	45	90
원거리 (50cm 이상)	15	80

표 5. 숫자 조합 결과

표시값	후처리 없음	NMS 만	전체 파이프라인
118g	111111888	18	118
291g	222999111	291	291

4.2 ACT 순차 적재 (시뮬레이션)

표 6. 적재 성공률 (% , 시뮬레이션, 각 50 회)

시연 설계 / 수	1 층	옆	2 층	연속
여유 1.5mm, 로봇 쪽 벽 / 100	76	84	50	28
여유 9mm, 로봇 쪽 벽 / 100	90	88	72	62
여유 9mm, 같은 벽 / 100	[]	[]	[]	[]
같은 벽 / 200	[]	[]	[]	[]
같은 벽 / 500	[]	[]	[]	[]
같은 벽 / 1000	[]	[]	[]	[]
같은 벽 + DART / 200	[]	[]	[]	[]
같은 벽 + DART / 1000	[]	[]	[]	[]




그림 4. 저울 위 통의 회전각과 단계별 결과 (여유 9mm, 로봇 쪽 벽, 시연 100)

표 6은 단계별 성공률(각 50 회)과 세 단계를 이어 수행한 연속 성공률(50 회)이다. 초기 시연(여유 1.5mm, 100 회)의 단계별 성공률은 1 층 76%, 옆 84%, 2 층 50%였으나, 앞 단계의 배치 오차가 다음 단계로 넘어가 연속 성공률은 28%에 그쳤다. 실패의 대부분은 고정 집게가 통 벽 위에 걸려 끝까지 내려가지 못한 채 닫힌 경우였다. 파지 여유를 9mm로 둔 시연으로 같은 100 회를 학습하면 단계별 90%, 88%, 72%, 연속 62%로 높아졌다. 남은 실패 25 건 중 24

건은 저울 위 통이 +7.5° 넘게 돌아간 시행에서 일어났다(그림 4). 이 구간의 실패율은 49%, 나머지는 1%로, 전문가가 잡는 벽을 바꾸는 구간과 일치한다. 이때 정책은 앞벽과 옆벽 시연의 중간인 모서리 쪽으로 가서 집계를 벽 위에 얹은 채 닫았다. 늘 같은 벽을 잡는 시연으로 바꾸자 같은 100 회에서 단계별 []%, []%, []%, 연속 []%였다.

같은 벽 시연을 200, 500, 1000 회로 늘리면 연속 성공률은 []%, []%, []%였다. 시연 잡음을 주입한 DART 정책은 같은 1000 회에서 단계별 []%, []%, []%, 연속 []%였고, 200 회에서는 연속 []%(일반 200 회 []%)였다. 추론만 바꾸는 시간 양상블[4]은 로봇 쪽 벽 시연 200 회 정책의 연속 성공률을 []%에서 []%로 바꾸었다. 모방학습 성능이 시연 수보다 시연의 다양성과 일관성에 좌우된다는 보고[16]와 같이, 시연 수를 늘리는 것만으로는 시연 설계의 효과를 대신하기 어렵다.




그림 5. ACT 정책의 연속 적재 장면

실제 셀에서도 1 층 적재 정책이 MCP 신호에 따라 통을 집어 적재하는 것을 확인하였으나, 위치 오차와 제어 지연으로 실패하는 경우가 관찰되었다. 현장 측정 기록이 남아 있지 않아 실제 수치와의 비교는 하지 않았다.

V. 결론

본 논문은 Jetson Orin Nano에서 YOLOv8 기반 7-segment 무게 인식과 MCP 트리거로 호출되는 단계별 ACT 정책을 결합하여, 무게 판정부터 1 층·옆·2 층 순차 적재까지 이어지는 스마트 팩토리 셀을 구현하였다. 인식부는 캡처 59.5 FPS, 중거리 정확도 90%, 정분류율 91.7%, 응답 810ms를 실측으로 확인하였다. 로봇 파손 이후 같은 조건을 재현한 시뮬레이션에서는 단계별 성공률이 높아도 연속 적재에서 오차가 누적됨을 보였고, 실패의 원인이 정책보다 시연 설계(파지 여유, 잡는 벽의 일관성)에 있음을 파지 위치와 장면 분석으로 밝혀 시연 100 회의 연속 성공률을 28%에서 []%로 높였다. 시뮬레이션 결과는

스크립트 시연과 단순화된 접촉 모델에 기반하므로 실제 원격조작 시연의 성능과 다를 수 있으며, 향후 로봇을 복구하여 같은 파지 설계로 실측 검증할 예정이다.

참고문헌

- [1] International Federation of Robotics, World Robotics 2024: Industrial Robots, IFR, 2024.
- [2] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in Proc. IEEE CVPR, pp. 779-788, 2016.
- [3] G. Jocher, A. Chaurasia, and J. Qiu, Ultralytics YOLOv8, <https://github.com/ultralytics/ultralytics>, 2023.
- [4] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, "Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware," in Proc. Robotics: Science and Systems (RSS), 2023.
- [5] R. Cadene et al., LeRobot: State-of-the-art Machine Learning for Real-World Robotics in PyTorch, <https://github.com/huggingface/lerobot>, 2024.
- [6] S. Ross, G. Gordon, and D. Bagnell, "A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning," in Proc. AISTATS, pp. 627-635, 2011.
- [7] Anthropic, Model Context Protocol, <https://modelcontextprotocol.io>, 2024.
- [8] E. Todorov, T. Erez, and Y. Tassa, "MuJoCo: A Physics Engine for Model-Based Control," in Proc. IEEE/RIS IROS, pp. 5026-5033, 2012.
- [9] M. Laskey, J. Lee, R. Fox, A. Dragan, and K. Goldberg, "DART: Noise Injection for Robust Imitation Learning," in Proc. CoRL, pp. 143-156, 2017.
- [10] Brian3D, Automatic Color Sorting Conveyor, MakerWorld, 2025.
- [11] ONNX Runtime developers, ONNX Runtime, <https://onnxruntime.ai>, 2021.
- [12] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in Proc. IEEE CVPR, pp. 770-778, 2016.
- [13] A. Vaswani et al., "Attention Is All You Need," in Proc. NeurIPS, pp. 5998-6008, 2017.
- [14] TheRobotStudio, SO-ARM100 / SO-101 Robot Arm, <https://github.com/TheRobotStudio/SO-ARM100>, 2025.
- [15] A. Mandlekar et al., "MimicGen: A Data Generation System for Scalable Robot Learning using Human Demonstrations," in Proc. CoRL, 2023.
- [16] F. Lin, Y. Hu, P. Sheng, C. Wen, J. You, and Y. Gao, "Data Scaling Laws in Imitation Learning for Robotic Manipulation," in Proc. ICLR, 2025.