

# Jetson Orin Nano 기반 YOLOv8 무게 인식과 ACT 모방학습을 이용한 스마트 팩토리 순차 적재와 시연 설계 분석

\*이지용, 김한민, 정철훈, 장민기, 고병철

계명대학교 컴퓨터공학전공

e-mail : yeez0612@naver.com

## Smart Factory Sequential Stacking with YOLOv8 Weight Recognition and ACT Imitation Learning: Demonstration Design Analysis

Jiyong Lee, Hanmin Kim, Cheolhun Jeong, Mingi Jang, and Byoung Chul Ko  
Dept. of Computer Engineering, Keimyung University

### Abstract

This paper presents an edge-AI smart-factory cell that sorts products by weight and stacks them with a low-cost robot arm, and a demonstration-design method that makes its imitation-learned stacking reliable. On a Jetson Orin Nano, a YOLOv8n model reads the 7-segment display of a digital scale (59.5 FPS capture, 91.7% correct sorting, 810 ms response); a bin of 118 g or more triggers stage-specific ACT (Action Chunking with Transformers) policies on an SO-101 arm that stack it on the first floor, beside the first bin and on top of it. Because the arm was damaged after the field tests, stacking was evaluated in a MuJoCo replica of the cell. With the initial 100 scripted demonstrations per stage only 28% of three-stage sequences succeeded. We traced the failures to how the demonstrations were made and propose three design rules (grasp clearance at the centre of the capture window, one consistent grasp feature, backing off before lifting) together with a pre-training audit that flags ambiguous grasp strategies as an empty band in the wrist angle at grasp time. The rules raised sequence success to 99.0% over 200 sequences, and re-running a stage while the scale still reads the bin made it 200/200. The rules carried over to a cup with a

handle ([ ] to [ ]%) and a rectangular box ([ ] to [ ]%). With domain randomization and a cluttered factory cell (conveyor, racks, posts, overhead cables in the camera view, parts close to the arm's path), one policy per stage stacked all three objects in two cell layouts with [ ]% average sequence success.

### I. 서론

제조·물류 현장은 인력 부족과 반복 작업에 따른 산업재해 문제로 자동화 수요가 커지고 있다[1]. 그러나 정해진 좌표를 반복하는 규칙 기반 셀은 제품 상태를 판정하거나 물체가 놓인 위치가 바뀌는 상황에 대응하기 어렵다. YOLO[2] 계열의 YOLOv8[3]은 에지 장치에서도 실시간으로 동작하며, ACT(Action Chunking with Transformers)[4]는 저가 로봇팔과 수십~수백 회의 시연만으로 정밀한 조작을 학습할 수 있음을 보였고 LeRobot[5]이 이를 SO-101 로봇팔에 공개하였다. 그러나 모방학습은 앞선 동작의 작은 오차가 다음 상태를 학습 분포 밖으로 밀어내 오차가 누적되며[6], 같은 상황에서 시연 동작이 서로 다르면 정책이 그 사이의 동작을 내어 실패한다[18]. 순차 적재에서는 이 오차가 단계를 넘어 쌓인다.

본 논문은 Jetson Orin Nano에서 디지털 저울의 7-segment 표시값을 YOLOv8로 판독하여 기준 무게(118g) 이상인 통을 선별하고, TCP 트리거 신호로 단계별 ACT

정책을 호출하여 SO-101 이 통을 1 층, 첫 통 옆, 첫 통 위(2 층) 순서로 적재하는 셀을 구현한다. 로봇팔이 파손된 뒤에는 같은 로봇 모델·카메라·제어 주기의 MuJoCo[7] 셀로 적재를 정량 평가하였다. 기여는 다음과 같다. ① 연속 적재 실패의 원인이 정책이 아니라 시연 설계에 있음을 밝히고, 세 가지 시연 설계 규칙과 잡는 방식의 같음을 학습 전에 찾는 시연 점검 지표를 제안하여 같은 시연 100 회의 연속 성공률을 28%에서 99.0%로 높였다. ② 인식부의 저울을 적재 성공 확인에도 써서 실패한 단계를 다시 실행하게 하였다 (200/200). ③ 규칙이 손잡이 컵과 직사각형 상자에도 그대로 통하고, 도메인 랜덤화와 공장형 잡동사니 환경에서 세 물체·두 배치를 단계별 정책 하나로 적재할 수 있음을 보였다.

## II. 시스템 구성

그림 1 은 전체 구성이다. 색상 분류 컨베이어[9]는 RGB 센서로 큐브를 판별하여 파란 큐브(정상)만 디지털 저울 위의 통으로 보내고, 스테퍼 모터와 서보는 Arduino Mega 2560 이, 인식과 판단은 Jetson Orin Nano 가 맡는다. Jetson 은 저울 표시부를 USB 카메라로 촬영해 무게를 판독하고 118g 이상이면 로봇 실행기에 TCP 트리거 신호를 보낸다. 인식부는 캡처와 추론을 다른 스레드로 나누고 ONNX Runtime[10] 최적화를 적용하였으며, 표시부를 먼저 찾아 잘라 확대한 뒤 숫자를 다시 탐지하는 2 단계 디지털 줌과, 겹친 숫자 상자를 자릿수 구역별로 정리하는 조합 규칙으로 '118'을 읽는다. 로봇은 손목·상단 카메라와 6 관절 SO-101 이며, 실행기는 단계 신호를 받으면 해당 정책을 실행하고 홈 자세로 돌아와 다음 신호를 기다린다. ACT 는 영상과 관절값으로부터 앞으로 100 스텝의 관절 목표값을 한 번에 예측하며 (ResNet18[11]·Transformer[12]·CVAE), 작업 지시문을 쓰지 않으므로 단계마다 정책을 따로 학습하였다.




그림 1. 시스템 구성

## III. 제안 방법

### 3.1 시뮬레이션 셀

MuJoCo 로 실제 셀을 재현하였다(그림 2). 공식 SO-101 모델[13]에 실제와 같은 카메라 배치, 30Hz 제어, 관절 목표값 행동 공간, 160×120 영상을 썼다. 통은 64×64×52mm(벽 2mm), 123g 이며, 저울 위 통은 위치  $\pm 20\text{mm}$ ·방향  $\pm 20^\circ$ , 먼저 쌓인 통은 목표에서  $\pm 8\text{mm}$ · $\pm 5^\circ$ 로 무작위화하였다. 시연은 역기구학 기반 스크립트 전문가로 만들었으며(ACT 도 시뮬레이션 과제에 스크립트 시연을 사용[4], 자동 시연 생성[14]), 구간 속도와 경유점을 흔들어 사람 시연의 변동을 흉내 내고 성공한 시연만 남겼다. 학습은 실제 시스템과 같은 LeRobot 0.3.3 ACT 기본 설정(체크 100, 배치 8)으로 단계별 30,000 스텝이다.




그림 2. 시뮬레이션 셀 (a) 전체 (b) 손목 카메라 (c) 상단 카메라 (d) 컵 (e) 직사각형 상자 (f) 공장형 환경

### 3.2 실패 기반 시연 설계 규칙

연속 평가의 실패 장면을 재생하여 원인을 찾고, 다음 세

규칙으로 시연을 고쳤다. R1(파지 여유): 고정 집게를 벽 바깥 9mm 에 두고 내려가, 집게가 벽을 사이에 둘 수 있는 범위(바깥 0~17mm)의 가운데로 접근한다. 초기 설계 (1.5mm)는 안쪽으로 3mm 만 어긋나도 집게가 벽 위에 걸렸다. R2(일관된 파지 위치): 물체가 돌아가 있어도 늘 같은 부위를 잡는다. 로봇과 가장 가까운 벽을 잡으면 통이 약 8° 넘게 돌아갈 때 잡는 벽이 바뀌어, 카메라에는 거의 같은 장면인데 시연 동작이 두 갈래가 된다. R3(물러나기): 2 층에 놓은 뒤 그리퍼를 벌리고 벽 바깥으로 5mm 물러났다가 올라간다. 공장 올라가면 2mm 벽 위의 통을 끌어 올려 기울게 하였다.

### 3.3 학습 전 시연 점검

R2 위반은 학습 전에 찾을 수 있다. 각 시연에서 그리퍼가 닫히는 순간의 손목 회전각을 모아 정렬하고, 이웃한 값 사이의 가장 넓은 빈 구간을 쟀다. 잡는 방식이 하나면 각도가 물체 방향을 따라 연속으로 퍼지지만, 두 방식이 섞이면 두 무리 사이에 수십 도의 빈 구간이 생긴다(그림 3). 학습 없이 시연만으로 계산되며, 빈 구간이 큰 시연 집합은 R2 에 맞게 다시 만든다.




그림 3. 잡는 순간의 손목 회전각 (1 층 시연, 주황 사랍식, 파랑 R2)

### 3.4 무게 확인 재시도

단계를 실행한 뒤 저울 무게를 다시 읽어, 통이 저울에 남아 있으면(60g 이상) 같은 단계를 다시 실행한다(최대 3 회). 시뮬레이션에서는 저울 판에 걸리는 수직 접촉력을 무게로 환산하였다(가득 찬 통 123.0g, 빈 저울 0g). 무게 인식부가 적재의 성공 판정까지 맡아 두 부분이 하나의 공정으로 이어진다.

### 3.5 공장형 환경 무작위화

현장의 조명·작업대·카메라 장착 위치 변화에 대비해 조명 (0.45~1.7 배), 작업대 색, 카메라 위치(상단 ±12mm·±2.5°, 손목 ±3mm)를 무작위화하였다(도메인 랜덤화[16]). 더 나아가 실제 공장처럼 컨베이어(움직이는 물건 포함), 다른 색 통이 놓인 선반, 기둥, 제어함, 상단 카메라 앞을 지나가는 천장 케이블, 경고 테이프, 부품 16 종 (8~16 개), 닳은 빈 통, 지나가는 물체, 깜빡이는 조명을 매번 다르게 두었다(그림 2(f)). 물건을 팔과 부딪히지 않는

곳에 두기 위해, 전문가 시연 120 회에서 팔과 들고 가는 통이 각 지점 위로 내려온 최저·최고 높이를 5mm 격자로 기록한 작업 공간 지도를 만들고, 물건은 최저 높이보다 15mm 이상 낮게(케이블은 최고 높이 40mm 위로) 두었다. 이 지도는 실제 셀에서 물건을 두면 안 되는 구역 표시로도 쓸 수 있다. 통의 색은 공정의 판정 기준이므로 바꾸지 않았다.

### 3.6 평가 방법

단계별 평가는 앞 단계 통을 목표 근처에 둔 상태에서 해당 정책만, 연속 평가는 실제 셀처럼  $\pi_1 \rightarrow \pi_2 \rightarrow \pi_3$  을 같은 장면에서 이어서 실행한다(각 50 회, 시연에 쓰지 않은 시드). 통 중심이 목표에서 15mm, 높이가 8mm, 기울기가 10° 이내이고 먼저 쌓인 통이 10mm 이상 밀리지 않으면 성공이며, 잡동사니 환경에서는 주변 물건을 10mm 이상 밀거나 구조물에 닿아도 실패로 보았다.

## IV. 실험 결과

### 4.1 무게 인식

표 1 은 Jetson Orin Nano 에서 조건별 20 회 반복 측정한 인식부 성능이다. 오분류 5 건은 주로 조명이 고르지 않은 조건에서 '8'을 '1'로 읽은 경우였다.

표 1. 무게 인식부 실측 성능 (Jetson Orin Nano)

| 항목                     | 결과                           |
|------------------------|------------------------------|
| 숫자 탐지 YOLOv8n (13 클래스) | mAP50 86.3%, mAP50-95 65.6%  |
| 캡처 속도                  | 1.2 → 59.5 FPS (캡처·추론 분리)    |
| 중거리 / 원거리 정확도          | 45 → 90% / 15 → 80% (2 단계 중) |
| 기준값(118g) 분류 정분류율      | 91.7% (55/60)                |
| 인식부터 명령 전송까지 응답        | 약 810ms                      |

### 4.2 시연 설계 규칙 (시뮬레이션)

표 2. 시연 설계별 적재 성공률 (% , 각 50 회)

| 시연 설계 (단계별 시연 수)   | 1 층 | 옆   | 2 층 | 연속 (95% CI) |
|--------------------|-----|-----|-----|-------------|
| ① 초기 설계 (100)      | 76  | 84  | 50  | 28 (17-42)  |
| ② +R1 여유 9mm (100) | 90  | 88  | 72  | 62 (48-74)  |
| ③ +R2 같은 벽 (100)   | 100 | 100 | 86  | 82 (69-90)  |
| ④ +R3 물러나기 (100)   | 100 | 100 | 100 | 96 (87-99)  |
| ④ (1000)           | 100 | 98  | 100 | 94 (84-98)  |
| ④ + 무작위화 (1000)    | 100 | 98  | 98  | 98 (90-100) |

초기 시연(①)은 단계별 76%, 84%, 50%였으나 앞 단계 오차가 넘어가 연속 28%에 그쳤다. R1 로 집게가 벽 위에 걸리는 실패가 줄었고(연속 62%), 남은 실패 25 건 중 24

건은 전문가가 잡는 벽을 바꾸는 회전 구간에서 일어났다. 이 시연은 3.3 절의 점검에서 손목 각도에 53.1°의 빈 구간을 보였고, 시연을 200 회로 늘리면 오히려 연속 36%로 낮아졌다. R2 를 적용하자 빈 구간이 1.5°로 사라지고 집기 실패가 없어졌으며(③, 연속 82%), R3 까지 적용한 ④는 연속 96%, 장면 200 개에서 99.0%(95% CI 96.4–99.7%)(평균 위치 오차 3.6, 4.4, 5.9mm)였다. ④의 시연을 1000 회로 늘리거나 DART[8] 잡음을 넣어도 94%, 96%로 나아지지 않아, 시연 수가 시연 설계를 대신하지 못했다[15]. 남은 실패는 통을 집지 못해 저울에 남은 경우였으며, 무게 확인 재시도로 첫 시도 198/200 에서 200/200 가 되었다. 영상을 가리면 0/10 으로 정책은 영상에서 통을 찾아 움직였고, 카메라를 하나만 쓰면 상당만 96%, 손목만 70%로 상당 카메라가 핵심이었다.

#### 4.3 다른 물체로의 일반화

규칙이 통에만 맞춘 것이 아님을 확인하기 위해 잡을 곳이 다른 이유로 애매한 두 물체를 더 시험하였다(그림 2(d)(e)). 손잡이 컵(육각, 지름 70mm)은 손잡이가 로봇 쪽( $\pm 30^\circ$ )을 향해 로봇에 가까운 면이 막히므로 사람처럼 잡으면 손잡이의 왼쪽·오른쪽 중 가까운 쪽으로 갈리고, R2 로는 늘 손잡이 오른쪽 면을 잡는다. 직사각형 상자(90×60mm)는 로봇 쪽 벽을 잡으면 긴 벽과 짧은 벽이 바뀌어 놓인 방향까지 달라지며, R2 로는 늘 같은 짧은 벽을 잡는다. 두 설계 모두 R1·R3 은 같다.

표 3. 물체별 시연 점검과 연속 성공률 (시연 100 회, 각 50 회)

| 물체 (애매한 이유)      | 빈 구간(°) 사람식<br>→R2 | 연속(%) 사람식<br>→R2 |
|------------------|--------------------|------------------|
| 정사각형 통 (네 벽이 같음) | 53 → 4             | 62 → 96          |
| 손잡이 컵 (손잡이 좌·우)  | 66 → 7             | [ ] → [ ]        |
| 직사각형 상자 (긴·짧은 벽) | 53 → 4             | [ ] → [ ]        |

표 3 과 같이 사람식 시연은 세 물체 모두 손목 각도에 큰 빈 구간을 보였고, R2 로 고치면 빈 구간이 사라지며 연속 성공률이 올랐다. 점검 지표가 학습 전에 실패할 시연을 가려낸 것이다.

#### 4.4 환경 변화와 공장형 잡동사니

표 4. 잡동사니·공장형 환경의 연속 성공률 (% , 통, 각 50 회)

| 환경 (연속 성공률 %) | ④ (100) | +무작위화 | +잡동사니 | 통합  |
|---------------|---------|-------|-------|-----|
| 변화 없음         | 98      | 98    | 94    | [ ] |
| 잡동사니 전부       | 0       | 58    | 88    | [ ] |
| 잡동사니 팔 경로 5mm | 2       | 56    | [ ]   | -   |
| 공장형           | 0       | 10    | [ ]   | [ ] |
| 공장형+외관 무작위    | 0       | 10    | [ ]   | [ ] |

|                   |   |   |     |     |
|-------------------|---|---|-----|-----|
| 공장형 최대(16 개, 5mm) | 0 | 4 | [ ] | [ ] |
|-------------------|---|---|-----|-----|

조명·작업대·카메라 위치·관측 시연 등 15 가지 변화를 한 가지씩 주면 도메인 랜덤화 정책이 단계 평균 98%(무작위화 없이 89%)를 유지했으며, 밝기 정규화·CLAHE[17]를 더하면 95%로 오히려 낮아졌다. 표 4 는 실제로 부딪히는 잡동사니(물건 4~8 개, 닳은 통, 지나가는 물체)와 공장형 환경의 결과이다. 무작위화 없는 ④는 잡동사니 전부에서 0%로 떨어졌고, 잡동사니를 넣은 시연(+잡동사니, 1000 회)은 88%였다. 세 물체·두 배치·공장형 환경을 섞은 시연 1800 회로 단계별 정책 하나를 학습한 통합 정책은 공장형 환경에서 6 가지 물체·배치 조합 평균 [ ]%(최저 [ ]%), 외관까지 무작위화하면 [ ]%였다.

### V. 결론

본 논문은 Jetson Orin Nano 에서 YOLOv8 기반 7-segment 무게 인식과 TCP 트리거로 호출되는 단계별 ACT 정책을 결합한 스마트 팩토리 적재 셀을 구현하고, 시뮬레이션으로 적재를 정량 평가하였다. 연속 적재 실패의 원인이 시연 설계에 있음을 밝혀 세 가지 시연 설계 규칙과 학습 전 시연 점검 지표를 제안하였고, 시연 100 회의 연속 성공률을 28%에서 99.0%로, 무게 확인 재시도로 200/200 로 높였다. 규칙은 손잡이 컵과 직사각형 상자에도 통했으며, 공장형 잡동사니 환경에서도 단계별 정책 하나로 세 물체·두 배치를 적재하였다. 결과는 스크립트 시연과 단순화된 접촉 모델에 기반하므로, 향후 로봇을 복구하여 같은 규칙으로 실측 검증할 예정이다.

### 참고문헌

- [1] International Federation of Robotics, World Robotics 2024: Industrial Robots, IFR, 2024.
- [2] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in Proc. IEEE CVPR, pp. 779-788, 2016.
- [3] G. Jocher, A. Chaurasia, and J. Qiu, Ultralytics YOLOv8, <https://github.com/ultralytics/ultralytics>, 2023.
- [4] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, "Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware," in Proc. Robotics: Science and Systems (RSS), 2023.
- [5] R. Cadene et al., LeRobot: State-of-the-art Machine Learning for Real-World Robotics in PyTorch, <https://github.com/huggingface/lerobot>, 2024.
- [6] S. Ross, G. Gordon, and D. Bagnell, "A Reduction of Imitation Learning and Structured Prediction to No-

- Regret Online Learning,” in Proc. AISTATS, pp. 627-635, 2011.
- [7] E. Todorov, T. Erez, and Y. Tassa, “MuJoCo: A Physics Engine for Model-Based Control,” in Proc. IEEE/RSJ IROS, pp. 5026-5033, 2012.
  - [8] M. Laskey, J. Lee, R. Fox, A. Dragan, and K. Goldberg, “DART: Noise Injection for Robust Imitation Learning,” in Proc. CoRL, pp. 143-156, 2017.
  - [9] Brian3D, Automatic Color Sorting Conveyor, MakerWorld, 2025.
  - [10] ONNX Runtime developers, ONNX Runtime, <https://onnxruntime.ai>, 2021.
  - [11] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in Proc. IEEE CVPR, pp. 770-778, 2016.
  - [12] A. Vaswani et al., “Attention Is All You Need,” in Proc. NeurIPS, pp. 5998-6008, 2017.
  - [13] TheRobotStudio, SO-ARM100 / SO-101 Robot Arm, <https://github.com/TheRobotStudio/SO-ARM100>, 2025.
  - [14] A. Mandlekar et al., “MimicGen: A Data Generation System for Scalable Robot Learning using Human Demonstrations,” in Proc. CoRL, 2023.
  - [15] F. Lin, Y. Hu, P. Sheng, C. Wen, J. You, and Y. Gao, “Data Scaling Laws in Imitation Learning for Robotic Manipulation,” in Proc. ICLR, 2025.
  - [16] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, and P. Abbeel, “Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World,” in Proc. IEEE/RSJ IROS, pp. 23-30, 2017.
  - [17] K. Zuiderveld, “Contrast Limited Adaptive Histogram Equalization,” in Graphics Gems IV, Academic Press, pp. 474-485, 1994.
  - [18] S. Belkhale, Y. Cui, and D. Sadigh, “Data Quality in Imitation Learning,” in Proc. NeurIPS, 2023.